

Análise exploratória e mitigação do viés racial no processo de identificação racial

Isadora de Oliveira Caetano, isadora3caetano@usp.br¹
Valdinei Freire, valdinei.freire@usp.br¹

¹Escola de Artes, Ciências e Humanidades, Universidade de São Paulo

Resumo: Este artigo explora o viés racial no processo de identificação facial e propõe a mitigação desse problema por meio da técnica de programação linear. Os sistemas de identificação facial possuem falsos positivos, especialmente contra grupos minoritários. Com intuito de avaliar esse problema, dois cenários foram analisados de forma detalhada: um utilizando imagens do FairFace e outro com imagens do UTKFaces, a fim de medir a disparidade entre falsos positivos entre os diferentes grupos raciais. Para mitigar o problema, o método de programação linear foi aplicado, diminuindo a disparidade observada. Dessa forma, foi evidenciado o viés racial no processo de identificação facial e, a partir da aplicação da técnica programação linear, buscou-se garantir um processo mais justo.

Palavras-chave: Reconhecimento Facial; Viés Racial; Fairness; Identificação Facial

Abstract: This article explores racial biases in the facial identification process and proposes mitigating this problem through linear programming. Facial recognition systems have false positives, especially against minority groups. In order to evaluate this problem, two scenarios were analyzed in detail: one using FairFace images and the other using UTKFaces images, to measure the disparity in false positives between different racial groups. To mitigate the problem, the linear programming method was applied, reducing the observed disparity. Thus, we highlight racial biases in the facial recognition process and, through the application of linear programming techniques, seek to ensure a fairer process.

Keywords: Facial Recognition; Racial Bias; Fairness; Facial Identification.

1. Introdução

O reconhecimento facial já faz parte do nosso cotidiano, sendo utilizado para desbloquear celulares, acessar contas bancárias e entrar em locais como academias e prédios residenciais (ALI, 2021). Na cidade de São Paulo, por exemplo, foi criado o Programa Smart Sampa, que tem como objetivo instalar câmeras com sistemas de

reconhecimento facial em diversas áreas da cidade para aumentar a segurança e eficiência pública (MOLERO JUNIOR e BITTAR, 2025).

Ao longo dos anos, o reconhecimento facial vem melhorando constantemente. No entanto, esses processos apresentam um grande problema: o viés racial. Esse viés faz com que determinados grupos sejam privilegiados em relação a outros, sendo extremamente prejudicial (BUOLAMWINI e GEBRU, 2018). Em aplicações envolvendo sistemas de segurança pública, como Smart Sampa, esse viés cria falsos positivos que acarretam a abordagem e até a prisão de pessoas inocentes (BOEHM, 2026).

Neste estudo, a avaliação do viés racial no processo foi realizada a partir de imagens dos conjuntos UTKFace e FairFace. No cenário analisado, foram criados dois conjuntos de imagens: referência (*enrolment*) e alvo (*target*). Para investigação do viés racial, as imagens do conjunto de imagens alvo (*target*) mais similares foram selecionadas, com base no valor da similaridade do cosseno, às imagens do conjunto de imagens de referência (*enrolment*).

Para mitigação, aplicou-se o método de programação linear, que consiste na otimização de uma função linear sob restrições, com o objetivo de reduzir disparidades no processo de seleção de indivíduos com base na similaridade em relação ao conjunto *target*, promovendo maior equilíbrio entre os grupos raciais.

Os resultados mostraram que nos cenários analisados, tanto para as imagens do FairFace, quanto para as do UTKFace, havia disparidade na quantidade de indivíduos selecionados por raça. Com a técnica aplicada para mitigação, foi possível diminuir a diferença identificada.

2. Fundamentos Teóricos

2.1. Sistema de Reconhecimento Facial

Sistemas de reconhecimento tiveram um grande progresso nos últimos anos e, devido a sua ampla aplicação social, o tema virou foco de diversas áreas de pesquisa. Dessa forma, esses dispositivos estão sendo aplicados em mecanismos de controle de acesso, para vigilância e são utilizados para entretenimento, como realidade virtual (ALI, 2021).

2.1.1. Aquisição de imagens

A primeira etapa desses sistemas é a aquisição e processamento de imagens. A obtenção de imagens pode ser realizada a partir de imagens de redes sociais, como as imagens do conjunto FairFace, ou de pessoas públicas como políticos e celebridades, como PPB e o MS-Celeb (YUCER, 2024).

2.1.2. Detecção Facial

A segunda etapa é a detecção facial. Essa etapa consiste na detecção de um rosto e no alinhamento da imagem, o que é realizado por meio da identificação de referências faciais como extremidades dos olhos, boca e nariz (YUCER, 2024).

2.1.3. Extração de características

A extração de características é a terceira etapa no processo de reconhecimento facial, sendo a parte principal do processamento. Essa etapa pode afetar o desempenho geral do sistema (ALI, 2021). Para esse processo, diversos sistemas utilizam DCNNs (*Deep Convolutional Neural Networks*). As DCNNs são estruturas em múltiplas camadas. A camada convolucional recebe como entrada as imagens e extraí características a partir de filtros denominados de kernels. Ao final da etapa de convolução, a camada de *pooling* diminui o tamanho dos dados, mantendo as informações mais importantes a partir da média ou valor máximo das regiões das imagens. A seguir, as camadas totalmente conectadas transformam os dados em um vetor e realizam a classificação da imagem, por exemplo. Na última etapa, o match de característica é realizado (YUCER, 2024).

2.1.4. Seleção de características

A etapa de seleção de características refere-se ao processo de diminuir a complexidade a partir da redução da dimensionalidade do vetor de características. Essa etapa diminui o custo do sistema, impactando no seu desempenho (ALI, 2021).

2.1.5. Matching de características

Após o processo para obter as principais características de uma imagem, é realizado o *feature matching* que pode ser feito por meio da identificação ou verificação facial.

Na verificação facial, duas imagens são comparadas para confirmar se ambas pertencem ao mesmo indivíduo. Nesse processo, o sistema possui a identidade declarada e precisa validá-la. A verificação é feita comparando os *embeddings* das duas imagens por meio de uma medida de similaridade. Caso o valor de similaridade seja maior ou igual ao limiar (*threshold*), considera-se que as imagens pertencem a mesma pessoa (YUCER, 2024).

A identificação facial consiste na comparação de uma imagem com várias outras que estão em um banco de imagens com intuito de descobrir a identidade de um indivíduo. Assim como no processo de verificação facial, *embeddings* das imagens são comprados a partir da similaridade, e, com base no limiar, decide-se se as imagens pertencem a mesma pessoa (YUCER, 2024).

2.2. Viés Racial no Reconhecimento Facial

Para entender o viés racial no reconhecimento facial, é importante trazer o conceito de racismo algorítmico. Segundo Tarcízio Silva (2022), o racismo algorítmico é o modo pelo qual a disposição de tecnologias e imaginários sociotécnicos em um mundo moldado pela supremacia branca realiza a ordenação algorítmica racializada de classificação social, recursos e violência em detrimento de grupos minoritários.

Embora exista a crença que a tecnologia e consequentemente algoritmos são neutros, estudos mostram que isso não é verdade (SANTOS, ZANATTA, 2025). Um dos exemplos mais conhecidos é a investigação do sistema COMPAS, realizada pela ProPublica. O COMPAS é um sistema que mede o risco de um indivíduo reincidir, e a medida é utilizada por juízes no julgamento de um réu. A investigação da ProPublica descobriu que o software possui taxa de falso positivo maior para pessoas afroamericanas, enquanto, para pessoas brancas, o sistema apresentava uma maior taxa de falso negativo (ANGWIN, 2016).

No contexto do reconhecimento facial, diversos estudos identificaram vieses que acarretam diferenças de tratamento em grupos minoritários. Esses estudos mostram que o viés é principalmente contra mulheres, pessoas de pele mais escura e pessoas mais jovens (BUOLAMWINI, 2018).

Em todas as etapas do reconhecimento, pode existir viés, desde a aquisição de imagens até a avaliação do resultado de verificação ou identificação facial (YUCER, 2024).

No processo de aquisição de imagens, os conjuntos de imagens utilizados podem ser pouco diverso racialmente, o que causa viés de amostragem. Na etapa de localização facial, detectores faciais podem ter dificuldade em identificar o rosto de pessoas de pele mais escura. Dentro da etapa de representação facial, na qual os *embeddings* são criados, existe o viés de hiper parâmetro, que está relacionado aos parâmetros selecionados da DCNN que podem não ser ideais para todos os grupos raciais. (YUCER, 2024).

O processo de identificação e verificação facial também são afetados por viés de avaliação. Isso ocorre quando o conjunto de imagens de referência não representa a população do conjunto de imagens alvo. Outro fator é o viés do *threshold*, uma vez que um *threshold* fixo pode influenciar, por exemplo, no FMR (false match rate) de um grupo racial. Além disso, decisões no sistema de verificação ou identificação facial, como a função de cálculo de similaridade ou quantidade de pessoas por imagem.

2.3. Fairness

Não há uma definição única de *fairness*. Entre suas definições, pode-se citar *Individual Fairness*, *Group Fairness* e *Equal Opportunity*.

Individual Fairness refere-se ao tratamento igualitário a indivíduos semelhantes, então um algoritmo justo deve prover previsões similares para indivíduos similares. No contexto do reconhecimento facial, se imagens distintas são consideradas similares a partir de alguma métrica, então a classificação deve ser similar (YUCER, 2024).

Group Fairness ou *Demographic Parity* refere-se a previsões de um modelo seja independente de um atributo sensível. Nesse caso, a proporção de resultados positivos, por exemplo, deve ser a mesma entre diferentes grupos, garantindo uma distribuição igual de decisões (YUCER, 2024).

O conceito de *Equalized Odds* ou *Equal Opportunity* busca garantir que a previsão de um modelo seja independente do atributo sensível condicionado ao valor real. Nesse contexto, o conceito tem o intuito de garantir que diferentes grupos devam ter taxas de verdadeiros positivos e falsos positivos semelhantes. (YUCER, 2024).

2.4. Mitigação do viés racial no Reconhecimento Facial

As etapas do reconhecimento facial podem ser classificadas em 3 categorias: Pré processamento, Processamento e Pós processamento (Kotwal e Marcel, 2026).

A mitigação de viés na etapa de pré-processamento tem maior foco na amostra de imagens que serão utilizados na etapa de processamento (Kotwal e Marcel, 2026). Nesse contexto, o estudo de Klare et al. (2012) propôs duas estratégias: treinar modelos com imagens de grupos específicos para melhorar o reconhecimento facial nesses grupos e a seleção dinâmica de imagens.

Na etapa de processamento, estudos focam na etapa de extração de características de imagens, mais especificamente a criação dos *embeddings* (Kotwal e Marcel, 2026). O estudo de Wang e Deng (2020), com intuito de reduzir a diferença na dispersão de característica entre grupos raciais, propõe uma rede de balanceamento racial baseado em aprendizado por reforço, aplicando margens adaptativas. A partir dessa estratégia, a dispersão de características se tornou mais equilibrados entre os grupos étnicos

Os métodos no Pós Processamento são focados em alterar a representação de características (*embeddings*) ou no cálculo de similaridade entre os *embeddings* (Kotwal e Marcel, 2026). Esses métodos, em comparação com estratégias para mitigação no pré-processamento e processamento, são menos comuns, mas também garantem a diminuição de viés. Com foco na alteração de *embeddings*, o estudo de Morales et al. (2021) propõem o SensitiveNets que remove as características sensíveis, por exemplo raça e gênero, das representações de características. Na etapa relacionada à aplicação do cálculo de similaridade para pontuar a correspondência entre imagens, o estudo de Terhörst et al. (2020) apresenta uma estratégia de normalização de pontuação justo não supervisionado baseado em *fairness*, assim com intuito de tratar indivíduos similares de forma semelhante.

2.5. Programação Linear

A programação linear é uma ferramenta utilizada para resolver problemas de procura combinatória como problemas de planejamento e alocação de recursos (MATOUŠEK e GÄRTNER).

O objetivo da programação linear é encontrar o vetor $x \in \mathcal{R}^n$ entre todos os vetores que maximiza ou minimiza o valor de uma função linear (função objetivo), satisfazendo um dado sistema de equações lineares e inequações (MATOUŠEK e GÄRTNER). A função objetiva é representada da seguinte forma:

$$c^t x = c_1 x_1 + c_2 x_2 + \dots + c_n x_n \quad (1)$$

Onde $c \in \mathcal{R}^n$

A equação linear e as inequações, denominadas de restrições, possuem o seguinte formato:

$$a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n (\leq \geq) b \quad (2)$$

$$a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n (=) b \quad (3)$$

...

$$a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n (=) b \quad (4)$$

Sendo $x_i \geq 0$, $i = 1, \dots, n$ e $b \in \mathcal{R}^m$

Resumidamente, a programação linear busca maximizar o valor de $c^t x$ entre todos os vetores $x \in \mathcal{R}^n$ satisfazendo $A_x \leq b$, onde A é uma matriz real $m \times n$ e $c \in \mathcal{R}^n$ e $b \in \mathcal{R}^m$ (MATOUŠEK e GÄRTNER).

3. Metodologia

Este estudo tem como objetivo investigar a presença de viés racial no processo de identificação facial e propor uma forma de mitigação usando Programação Linear. Com esse propósito, foram utilizados os conjuntos de imagens UTKFace e FairFace.

O UTKFace possui 24.125 imagens e classifica os indivíduos como *Black*, *White*, *Asian*, *Indian* e *Others* (DE OLIVEIRA, 2025). O FairFace possui 108.501 imagens e classifica os indivíduos como *Black*, *White*, *Latino/Hispanic*, *Indian*, *East Asian*, *Southeast Asian* e *Middle Eastern*. As imagens do FairFace estão divididas em dois conjuntos: Train e Val (KÄRKKÄINEN e JOO, 2019).

Ambos os conjuntos foram escolhidos porque são acessíveis, possuem boa diversidade racial em comparação com outros conjuntos e contém identificação racial dos indivíduos nas imagens, o que facilita o processo de análise do viés racial (DE OLIVEIRA, 2025).

3.1. Etapas da metodologia

3.1.1. Etapa 1: Análise de embeddings

Primeiramente, os *embeddings* (vetor de características) das imagens dos conjuntos foram extraídos. Para isso, foi utilizado o modelo `buffalo_l` da biblioteca InsightFace da linguagem Python. Após a extração, cada imagem foi representada por um *embedding* de 512 dimensões. Posteriormente, foi realizada uma análise exploratória da disposição dos *embeddings* utilizando o método de visualização UMAP. *Uniform Manifold Approximation and Projection* (UMAP) é um algoritmo que projeta dados com alta dimensão em um espaço de menor dimensão, mantendo informações essenciais (THEVAPALAN, 2025).

3.1.2. Etapa 2: Criação dos cenários exploratórios

Neste estudo, não há verdadeiros positivos, uma vez que os conjuntos FairFace e UTKFace não possuem separação pares de imagens da mesma pessoa.

O problema foi tratado como um cenário de identificação 1:N, no qual um conjunto representa indivíduos de referência, denominado de *enrolment* e o outro conjunto representa indivíduos alvos, denominado de *target*.

As similaridades entre os *embeddings* foram calculadas. O cálculo da similaridade foi realizado com base na similaridade do cosseno, que calcula a similaridade de dois pontos dados com base na direção em que estão apontando, sendo que o valor -1 indica que os vetores direções opostas e 1 indica que os vetores apontam para mesma direção (KRANTZ e JONKER, s.d). Posteriormente, 10% dos *embeddings* do conjunto *target* mais semelhantes aos do *enrolment* foram selecionados.

Além disso, após a etapa de cálculo das similaridades, filtrou-se as similaridades acima de 0,65 com intuito de retirar imagens iguais e imagens da mesma pessoa. Esse valor foi baseado no valor da similaridade do cosseno dos pares de imagens da mesma pessoa do conjunto LFW (HUANG, 2007). Dessa forma, o nosso intuito foi selecionar as

imagens de pessoas distintas mais semelhantes conforme o valor da similaridade do cosseno.

3.1.3. Etapa 3: Mitigação

Inicialmente, um modelo MLP foi treinado e testado. Esse modelo foi utilizado para classificar a raça de uma pessoa a partir dos *embeddings* extraídos de uma imagem. Posteriormente, com intuito de aplicar *fairness* no cenário criado, empregou-se o conceito de Programação Linear para diminuir a diferença de quantidade de pessoas selecionadas por raça.

No contexto deste estudo, a função objetivo definida da seguinte maneira:

$$- N \times Prob(X) \times SimMax \quad (5)$$

Sendo N a quantidade de *embeddings* do conjunto *target*, $SimMax$ o vetor com valores da similaridade do *embedding* do conjunto *target* mais similar a um *embedding* do conjunto *enrolment* e $Prob(X)$ a probabilidade de um *embeddings* ser selecionado sem condições.

Assim, a função busca maximizar o número de *embeddings* selecionados do conjunto *target* que são mais similares aos *embeddings* do conjunto *enrolment*. As restrições são representadas a seguir:

$$Prob(X) \times N \leq b \quad (6)$$

A equação acima indica a restrição acerca da quantidade de *embeddings* selecionados, que deve ser menor igual ao *budget* (quantidade total de *embeddings* selecionados).

$$Prob(x_i) = Prob(base) \quad (7)$$


A equação acima estabelece que a probabilidade de pessoas selecionadas de um grupo racial deve ser igual a probabilidade de pessoas selecionadas do grupo base, definida como o grupo com menor número de selecionados.

3.2. Aplicação da metodologia

3.2.1. UTKFace

Na primeira etapa, analisando a visualização dos *embeddings* do conjunto UTKFace, identificou-se que indivíduos de raças distintas entre 0 e 10 anos estavam aglomerados na mesma região, como mostra a figura 1. Então, para evitar a influência desse aglomerado, os *embeddings* desses indivíduos foram desconsiderados.

Figura 1 - Visualização dos *embeddings* utilizando UMAP, antes (esquerda) e após (direita) a remoção de indivíduos de 0 a 10 anos.



Fonte: A autoria

Na segunda etapa, devido à baixa quantidade de imagens do grupo Others após as filtragens, foi decidido retirar *embeddings* desse grupo. Assim, o conjunto *enrolment* possui 400 imagens para cada raça e o conjunto *target* possui 1000 imagens por raça.


Após comparar os conjuntos *target* e *enrolment*, foram removidos os pares com similaridade superior a 0,65. Como resultado, os grupos *White*, *Black*, *Asian* e *Indian* passaram a ter respectivamente 985, 960, 936 e 955 *embeddings* no conjunto *target*.

Na terceira etapa, para o conjunto de treino e teste do classificador de raça havia 500 *embeddings* para cada raça.

3.2.2. FairFace


Na primeira etapa, analisando os *embeddings* do conjunto FairFace identificou-se que imagens de pessoas de perfil estavam aglomeradas na mesma região, como mostra a figura 2. Então, para evitar a influência desse aglomerado, esses *embeddings* foram desconsiderados.

Figura 2 - Visualização dos *embeddings* utilizando UMAP do conjunto do val do FairFace, antes (esquerda) e após (direita) a remoção de *embeddings* de imagens de perfil.



Fonte: A autoria

Figura 3 - Visualização dos *embeddings* utilizando UMAP do conjunto do Train do FairFace, antes (esquerda) e após (direita) a remoção de *embeddings* de imagens de perfil.



Fonte: A autoria

Para o cenário do FairFace, o conjunto *enrolment* possui 700 imagens para cada raça e o conjunto *target* possui 4000 imagens por raça. Após comparar os conjuntos *target* e *enrolment* e retirar pares com mais de 0,65 de similaridade, os grupos *White*, *Black*, *East Asian*, *Indians*, *Latino/Hispanic*, *Middle Eastern* e *Southeast Asian* possuem respectivamente 3971, 3969, 3908, 3946, 3952, 3924 e 3942 *embeddings* no conjunto *target*.

Na terceira etapa, o conjunto usando para treino e teste possuía 1100 *embeddings* para cada raça.


4. Resultados e Discussão

4.1. Resultados cenário com imagens do UTKFace

Nos cenários criados com *embeddings* do UTKFace, pode-se identificar que pessoas da raça *White* foram selecionadas em menor quantidade em comparação com outras raças, enquanto *embeddings* de imagens do grupo *Asian* foram escolhidos em maior quantidade.

Para aplicar a mitigação, o MLP foi treinado e testado, utilizado para classificar a raça associada ao *embedding*. Como resultado, o classificador teve 0,72 de acurácia.

Figura 4 - Quantidade de *embeddings* selecionado por raça conforme *budget*, antes (esquerda) e após (direita) a aplicação da mitigação no cenário com imagens do UTKFaces.



Fonte: A autoria

Após a aplicação da técnica de programação linear para mitigação de viés, o número de indivíduos selecionados em cada grupo passou de:


- 83 para 113 no grupo *Black*;
- 24 para 51 no grupo *White*;
- 198 para 107 no grupo *Asian*;
- 95 para 113 no grupo *Indian*.

4.2. Resultados cenário com imagens do FairFace

No cenário com *embeddings* do FairFace, pessoas do grupo *East Asian* foram selecionadas em maior quantidade, enquanto pessoas do grupo *White* foram escolhidas em menor quantidade.

O classificador treinado e testado com *embeddings* do FairFace teve 0,56 de acurácia.

Figura 5 - Quantidade de *embeddings* selecionado por raça conforme *budget* antes (esquerda) e após (direita) a aplicação da mitigação no cenário com imagens do FairFace.



Fonte: A autoria

Após a aplicação da técnica de programação linear para mitigação de viés, o número de indivíduos selecionados em cada grupo passou de:

- 349 para 401 no grupo *Black*;
- 237 para 307 no grupo *White*;
- 585 para 383 no grupo *East Asian*;
- 407 para 448 no grupo *Indian*.
- 397 para 392 no grupo *Latino/Hispanic*
- 307 para 424 no grupo *Middle Eastern*
- 518 para 445 no grupo *Southeast Asian*

4.3. Discussão dos resultados

Para calcular o efeito da aplicação da mitigação, foi usado o conceito de *Demographic Parity*. Dessa forma, foi calculado a probabilidade de um *embedding* ser selecionado entre grupos raciais antes e depois da mitigação usando a seguinte fórmula:

$$P(\hat{Y} = 1 | X = x) = \frac{\text{número de selecionados da raça } x}{\text{quantidade de embeddings da raça } x \text{ no conjunto target}} \quad (8)$$

No cenário com imagens do UTKFace, após a mitigação, as probabilidades associadas aos grupos raciais foram modificadas.

Antes da mitigação, as probabilidades observadas foram:

- *Black*: 0,086
- *White*: 0,024
- *Asian*: 0,211
- *Indian*: 0,099

Após a mitigação, esses valores passaram para:

- *Black*: 0,117
- *White*: 0,053
- *Asian*: 0,114
- *Indian*: 0,118

A diferença de probabilidade entre o grupo com mais selecionado e o com menos selecionados era de 0,187, após a mitigação a diferença passou a ser de 0,066, com melhora de 35,3%

No cenário com imagens do FairFace, após a mitigação, as probabilidades associadas aos grupos raciais foram modificadas.

Antes da mitigação, as probabilidades observadas foram:

- *Black*: 0,087
- *White*: 0,059
- *East Asian*: 0,150
- *Indian*: 0,103
- *Latino/Hispanic*: 0,100
- *Middle Eastern*: 0,078
- *Southeast Asian*: 0,131

Após a mitigação, os valores passaram para:

- *Black*: 0,101
- *White*: 0,077
- *East Asian*: 0,098
- *Indian*: 0,113
- *Latino/Hispanic*: 0,099
- *Middle Eastern*: 0,108
- *Southeast Asian*: 0,112

A diferença de probabilidade entre o grupo mais selecionado e o menos selecionado era de 0,091, após a mitigação a diferença passou a ser de 0,036, uma melhora de 39,6%.

Dessa forma, o método de mitigação se mostra eficaz em reduzir disparidades entre grupos nos cenários com imagens do UTKFaces e FairFace. No entanto, pode-se observar que o método de mitigação proposto não elimina completamente a disparidade observada. Além disso, o grupo com menor número de selecionados em ambos os cenários ainda continua na mesma situação após a mitigação. Isso indica que, embora haja melhora nos cenários analisados, o procedimento proposto ainda apresenta limitações na correção das desigualdades entre grupos raciais.

5. Considerações Finais

O presente estudo investigou o viés racial no processo de identificação facial utilizando imagens do conjunto FairFace e UTKFace e propôs uma forma de mitigação do viés identificado utilizando a técnica de programação linear

A análise do viés racial foi realizada em dois cenários: um com imagens do UTKFaces e outro com imagens do FairFace. A partir das análises dos cenários, foi possível identificar disparidade no número de selecionados entre categorias raciais distintas. Em ambos os cenários o grupo White foi selecionado em menor quantidade. Assim, nesse contexto, esse grupo estaria em vantagem, uma vez que incidência de falsos positivos foi menor em comparação aos demais grupos raciais.

Com a aplicação da técnica de programação linear, foi possível diminuir a disparidade observada. Para o cenário com imagens do UTKFaces, a discrepância entre as probabilidades de seleção do grupo racial mais selecionado (*Asian*) e do menos selecionado (*White*) foi reduzida em 35,3%. No cenário com imagens do FairFace, a diferença entre a probabilidade de seleção entre o grupo mais selecionado (*East Asian*) e o grupo menos selecionado (*White*) teve uma diminuição de 39,6%.

Este estudo apresenta limitações, haja vista que os conjuntos UTKFaces e FairFace não foram construídos com intuito de serem utilizados no processo de identificação facial, então não possuem pares de imagens da mesma pessoa. Dessa forma, não foi possível avaliar verdadeiros positivos e falsa não correspondência, o que possibilitaria uma análise mais completa.

6. Referências

ALI, Waqar; TIAN, Wenhong; DIN, Salah Ud; IRADUKUNDA, Desire; KHAN, Abdullah Aman. Classical and modern face recognition approaches: a complete review. *Multimedia Tools and Applications*, v. 80, n. 3, p. 4825-4880, 2021. DOI: <https://doi.org/10.1007/s11042-020-09850-1>.

ANGWIN, Julia et al. How we analyzed the COMPAS recidivism algorithm. ProPublica, 23 maio 2016. Disponível em: <https://www.propublica.org/article/how-we-analyzed-the-compas-recidivism-algorithm>. Acesso em: 22 de abril 2026.

BOEHM, Camila. Pesquisa aponta problemas e prisões indevidas a partir do Smart Sampa. Agência Brasil, 4 fev. 2026. Disponível em: <https://www.migalhas.com.br/depeso/452627/discriminacao-algoritmica-e-a-neutralidade-aparente-das-tecnologias>. Acesso em: 2 maio 2026.

BUOLAMWINI, Joy; GEBRU, Timnit. Gender shades: intersectional accuracy disparities in commercial gender classification. In: ACM Conference on Fairness, Accountability and Transparency, 2018. Disponível em: <https://api.semanticscholar.org/CorpusID:3298854>. Acesso em: 1 maio 2026.

DE OLIVEIRA, Alexandre Mundim. Influência do viés racial no uso de reconhecimento facial aplicado para controle de acesso. 2025. Dissertação (Mestrado) – Universidade de Brasília, Brasília, 2025. Disponível em: <https://ppee.unb.br/wp->

[content/uploads/2025/05/Dissertacao_na_versao_final-1.pdf](#). Acesso em: 15 de abril de 2026.

HUANG, Gary B.; RAMESH, Manu; BERG, Tamara; LEARNED-MILLER, Erik. Labeled Faces in the Wild: A Database for Studying Face Recognition in Unconstrained Environments. Amherst: University of Massachusetts Amherst, 2007. Technical Report. Disponível em: <https://vis-www.cs.umass.edu/lfw/lfw.pdf>. Acesso em: 12 abril 2026.

KÄRKKÄINEN, Kimmo; JOO, Jungseock. FairFace: face attribute dataset for balanced race, gender, and age. arXiv preprint, arXiv:1908.04913, 2019. Disponível em: <https://arxiv.org/abs/1908.04913>. Acesso em: 13 abril 2026.

KLARE, Brendan F.; BURGE, Mark J.; KLONTZ, Joshua C.; VORDER BRUEGGE, Richard W.; JAIN, Anil K. Face Recognition Performance: Role of Demographic Information. IEEE Transactions on Information Forensics and Security, v. 7, n. 6, p. 1789-1801, 2012. Disponível em: https://www.mitre.org/sites/default/files/pdf/11_4962.pdf. Acesso em: 29 abril 2026.

KOTWAL, K.; MARCEL, S. Review of demographic fairness in face recognition. IEEE Transactions on Biometrics, Behavior, and Identity Science, v. 8, n. 1, p. 20-45, jan. 2026. DOI: <https://doi.org/10.1109/TBIOM.2025.3601217>.

KRANTZ, Tom; JONKER, Alexandra. What is cosine similarity?. IBM Think, s.d. Disponível em: <https://www.ibm.com/br-pt/think/topics/cosine-similarity>. Acesso em: 2 maio 2026.

MATOUŠEK, Jiří; GÄRTNER, Bernd. What is linear programming? In: MATOUŠEK, Jiří; GÄRTNER, Bernd. Understanding and using linear programming. Berlin: Springer, 2007. cap. 1. Disponível em: <https://link.springer.com/book/10.1007/978-3-540-30717-4>. Acesso em: 2 maio 2026.

MOLERO JUNIOR, Luciano Finozzi; BITTAR, Marcelo Buczek. Reconhecimento facial na segurança pública e o racismo estrutural: análise constitucional do programa Smart Sampa (Decreto Municipal nº 63.552). 2025. Trabalho de Conclusão de Curso (Graduação em Direito) – Pontifícia Universidade Católica de São Paulo, São Paulo, 2025. Disponível em: https://repositorio.pucsp.br/bitstream/handle/45746/1/TCC%20-%20Luciano%20Molero_MARCELO%20BUCZEK%20BITTA.pdf. Acesso em: 2 maio 2026.

MORALES, A.; FIERREZ, J.; VERA-RODRIGUEZ, R. SensitiveNets: Learning Agnostic Representations with Application to Face Recognition. arXiv preprint, 2019. Disponível em: <https://arxiv.org/abs/1902.00334>. Acesso em: 29 abril 2026.

ROSENBERG, Harrison; TANG, Brian; FAWAZ, Kassem; JHA, Somesh. Fairness properties of face recognition and obfuscation systems. arXiv, 2021. Disponível em: <https://arxiv.org/abs/2108.02707>. Acesso em: 2 maio 2026.

SANTOS, Bruno Bioni; ZANATTA, Rafael A. F. Discriminação algorítmica e a neutralidade aparente das tecnologias. Migalhas, 2025. Disponível em:

<https://www.migalhas.com.br/depeso/452627/discriminacao-algoritmica-e-a-neutralidade-aparente-das-tecnologias>. Acesso em: 20 abril de 2026.

SILVA, Tarcízio. Racismo algorítmico: inteligência artificial e discriminação nas redes digitais. São Paulo: Edições Sesc SP, 2022. Disponível em: assets.pubpub.org/eylph50q/51661883758444.pdf. Acesso em: 14 2026.

TERHÖRST, Philipp; KOLF, Jan Niklas; DAMER, Naser; KIRCHBUCHNER, Florian; KUIJPER, Arjan. Post-comparison mitigation of demographic bias in face recognition using fair score normalization. arXiv, 2020. DOI: <https://doi.org/10.48550/arXiv.2002.03592>.

THEVAPALAN, Arunn. Understanding UMAP: a comprehensive guide to dimensionality reduction. DataCamp, 4 nov. 2025. Disponível em: <https://www.datacamp.com/pt/tutorial/understanding-umap-guide-to-dimensionality-reduction>. Acesso em: 24 de abril de 2026.

WANG, Mei; DENG, Weihong. Mitigating Bias in Face Recognition Using Skewness-Aware Reinforcement Learning. In: IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2020. Proceedings [...]. [S. l.]: IEEE, 2020. p. 9319-9328. DOI: <https://doi.org/10.1109/CVPR42600.2020.00934>.

YUCER, Seyma; TEKTAS, Furkan; AL MOUBAYED, Noura; BRECKON, Toby P. Racial bias within face recognition: a survey. ACM Computing Surveys, v. 57, n. 4, p. 1–39, 2024. DOI: <https://doi.org/10.1145/3705295>.